

MVP: Construção de um Pipeline de Dados na Nuvem

Estudo do Impacto Financeiro dos Agrotóxicos e dos Fertilizantes no Custo de Produção da Batata-Inglesa em Minas Gerais

Aluna: Astrid Eleanor Altamirano Junqueira

Data: 12 de Setembro de 2026

1. Contexto de Negócios e Perguntas (Etapa 2 e 4.1)

Contexto e Objetivo:

O objetivo deste MVP é analisar o impacto financeiro estrutural que as classes de insumos (fertilizantes e agrotóxicos) exercem sobre o custo de produção por hectare da batata-inglesa (*Solanum tuberosum*) nas regiões de Bueno Brandão e Santa Rita de Caldas, no estado de Minas Gerais. O entendimento dessa dinâmica permite avaliar a vulnerabilidade do produtor rural diante de choques de oferta internacionais.

Perguntas de Negócio que o Pipeline Responde:

- **Pergunta Principal:** O custo dos agrotóxicos ou o custo dos fertilizantes tem maior impacto no aumento do custo total de produção da batata-inglesa em Minas Gerais?
- **PE1:** Qual classe de insumo historicamente representa o maior peso financeiro por hectare na produção de batata em MG?
- **PE2:** Como se comportou a volatilidade e o crescimento dos custos de fertilizantes em comparação com os agrotóxicos no período de 2017 a 2025 em Bueno Brandão?
- **PE3:** Existem diferenças entre os custos dos fertilizantes e agrotóxicos aplicados nas variedades (tipos de safra) de batata-inglesa na região de Bueno Brandão?

Licença dos Dados:

Os dados brutos utilizados são de origem Pública / Governo Aberto (ODC-By / CC-BY), extraídos das séries históricas oficiais de custos de produção agropecuária da Companhia Nacional de Abastecimento (CONAB).

2. Carga dos Dados (Etapa 4.2)

Estratégia de Ingestão:

Adotou-se uma abordagem híbrida de ingestão para a nuvem. Os dados consolidados da CONAB foram baixados e carregados manualmente para a plataforma **Databricks Free Edition (Community)**, utilizando a ferramenta de armazenamento do **Unity Catalog** dentro do catálogo privado da conta (`/Volumes/workspace/default/batata_volume/`).

A carga bruta foi executada pelo Spark lendo o arquivo `Batata CONAB.csv`. O pipeline realiza o tratamento imediato dos metadados para evitar falhas de persistência.

> 2 dataframes: df_bruto, df_original

¡Éxito total! Capa Bronze creada correctamente con columnas limpias.

Table +

Q 🔍 ⌵ □

	1.0 Estado	1.0 Regiao	1.2 ANO	1.0 Variedade	1.2 Fertilizante	1.2 Agrotoxicos
1	MG	Bueno Brandao	2017	Batata das Aguas	3702.42	4367.58
2	MG	Bueno Brandao	2018	Batata das Aguas	4954.47	4543.05
3	MG	Bueno Brandao	2019	Convencional	4954.47	4543.05
4	MG	Bueno Brandao	2020	Convencional	5206.6	4449.52
5	MG	Bueno Brandao	2021	Convencional	5805.75	4674.64
6	MG	Bueno Brandao	2022	Convencional	12644.6	5456.33
7	MG	Bueno Brandao	2023	Convencional	11800	8708.92
8	MG	Bueno Brandao	2024	Convencional	13286	11777.2
9	MG	Bueno Brandao	2025	Convencional	15544	11874.23
10	MG	Santa Rita de Cald...	2012	Batata das Aguas	2859.49	2255.12
11	MG	Santa Rita de Cald...	2013	Batata das Aguas	3280.98	2164.91
12	MG	Santa Rita de Cald...	2014	Batata das Aguas	3140.49	2474.96
13	MG	Santa Rita de Cald...	2015	Batata das Aguas	3917.34	2632.24
14	MG	Santa Rita de Cald...	2016	Batata das Aguas	4297.51	2967.66

⬇

14 rows21.779s runtime

Refreshed 25m ago

3. Modelagem e Catálogo de Dados (Etapa 4.3)

Arquitetura Medalhão:

- **Camada Bronze:** Os dados são extraídos idênticos à fonte e persistidos na tabela Delta `tabela_custos_batata_bronze` para garantir o histórico e a rastreabilidade.
- **Camada Silver:** Executa-se o processo de limpeza, tipagem correta e renomeação de campos com caracteres especiais inválidos para a tabela analítica `tabela_custos_insumos`.

Dicionário de Dados (Tabela Silver):

Nome do Campo	Descrição	Tipo de Dado	Regras de Negócio	Linhagem
ano	Ano de referência analítica da safra.	Integer	2012 a 2025	Extraído da CONAB.
regiao	Nome do município produtor em MG.	String	"Bueno Brandao" ou "Santa Rita de Caldas"	Padronizado na Silver.
variedade	Tipo de safra de cultivo da batata.	String	"Batata das Aguas" ou "Convencional"	Campo original da fonte.
fertilizante	Custo de fertilizantes por hectare.	Double	Valores decimais decimais positivos (> 0)	Coluna isolada e limpa.
agrotoxico	Custo de agrotóxicos por hectare.	Double	Valores decimais decimais positivos (> 0)	Coluna isolada e limpa.

4. Pipeline de Dados (Etapa 4.4)

O pipeline ETL foi unificado em um notebook estruturado no Databricks utilizando **PySpark** para o processamento distribuído de dados e **Pandas/Plotly** para a renderização de gráficos. O fluxo lê os dados do Volume, realiza a sanitização de strings, padroniza as colunas econômicas e persiste os resultados de forma definitiva no Data Lakehouse via tabelas Delta organizadas semanticamente.

Modelagem e Catálogo de Dados (Etapa 4.3)

Descrição da Tabela: `tabela_custos_insumos` (Camada Silver) Esta tabela armazena os custos limpos e padronizados de produção por hectare para a cultura da batata-inglesa em Minas Gerais, permitindo a comparação temporal e regional entre fertilizantes e agrotóxicos.

Nome do Campo	Descrição	Tipo de Dado	Domínio de Valores / Regras	Linhagem
ano	Ano de referência da safra analítica.	Integer	2012 a 2025	Extraído diretamente da fonte original CONAB.
regiao	Nome do município produtor em MG.	String	"Bueno Brandao", "Santa Rita de Caldas"	Padronizado para remover caracteres especiais, se necessário.
variedade	Variedade ou ciclo de cultivo da batata.	String	"Batata das Aguas", "Convencional"	Extraído da descrição do cultivo original.
fertilizante	Custo financeiro de fertilizantes por hectare (R\$/ha).	Double	Valores decimais positivos (> 0)	Coluna calculada/isolada dos custos brutos.
agrotoxico	Custo financeiro de agrotóxicos por hectare (R\$/ha).	Double	Valores decimais positivos (> 0)	Coluna calculada/isolada dos custos brutos.

5. Qualidade de Dados (Etapa 4.5)

Para garantir a confiabilidade analítica exigida pelo MVP, o pipeline executa testes automatizados de qualidade na camada intermediária antes de alimentar os painéis:

- Completude (Valores Nulos):** O notebook rodou uma verificação em todas as colunas e confirmou a existência de **0% de valores nulos**, comprovando a integridade da captura.
- Unicidade (Duplicados):** O Spark validou o total de 14 registros históricos contra 14 linhas únicas, constatando a **ausência completa de linhas duplicadas** no conjunto de dados.

6. Análise de Dados e Resposta às Perguntas (Etapa 4.5)

Justificativa Metodológica sobre o Uso do ANOVA:


É importante ressaltar que o teste estatístico ANOVA clássico não foi mantido na execução do pipeline final deste MVP, uma vez que a inconsistência na série temporal gerava distorções matemáticas (SingularMatrixWarning). A ferramenta é mencionada nesta análise exclusivamente com o objetivo de explicar o embasamento metodológico que levou à identificação dos vieses amostrais e à escolha da abordagem analítica de médias agrupadas puras.

- Resposta à Pergunta Principal & PE1 (Peso Estrutural):** Os dados reais demonstram que **os Fertilizantes exercem o maior impacto financeiro** no


custo de produção da batata-inglesa em Minas Gerais. Na distribuição de gastos registrada para a safra de 2025, os fertilizantes abocanharam **56,7%** do orçamento total de insumos, contra 43,3% dos agrotóxicos. Mesmo no período pré-crise, a média histórica de gastos com fertilização superava consistentemente o custo de defesa fitossanitária.

- **Resposta à PE2 (Comportamento e Volatilidade em Bueno Brandão):** Entre 2017 e 2025, o município de Bueno Brandão sofreu um crescimento agressivo nos custos. **Os Fertilizantes mostraram-se muito mais instáveis e imprevisíveis**, registrando um Coeficiente de Variação (CV) de **52,73%** (Média: R\$ 8.655,37/ha). Os Agrotóxicos apresentaram maior previsibilidade de mercado na série temporal, com volatilidade de **47,72%** (Média: R\$ 6.710,50/ha).
- **Resposta à PE3 (Diferença entre Ciclos de Safra):** Ao isolar o viés amostral causado pelo choque de oferta da crise internacional de 2022, a análise econômica real comprova que **a safra de 'Batata das Águas' (verão) é historicamente mais onerosa do que o ciclo Convencional** em condições de mercado equivalentes. Por ser cultivada obrigatoriamente no período de altas temperaturas e pluviosidade do verão de MG, essa safra exige um volume drástico de aplicações defensivas contra fungos e pragas. O modelo estatístico ANOVA clássico declarava erroneamente o ciclo Convencional como mais caro simplesmente porque a CONAB registrou seus dados durante o ápice da crise global de preços de 2022.



Evolução e Volatilidade de Custos em Bueno Brandão (2017 - 2025)



Comparativo de Custos: Fertilizantes vs Agrotóxicos por Ano



Distribuição de Gastos em 2025: Fertilizantes vs Agrotóxicos



7. Autoavaliação

A execução deste MVP proporcionou um aprendizado prático e profundo das responsabilidades diárias de um Engenheiro de Dados. O objetivo principal foi atingido com sucesso: construir um pipeline funcional de ponta a ponta na nuvem capaz de responder perguntas reais de negócio.

Dificuldades Encontradas:

A principal barreira técnica enfrentada decorreu das restrições de arquitetura e segurança do cluster gratuito do Databricks Community Edition (Spark Connect). O sistema gerava erros repetitivos de barramento de caminhos (`[DBFS_DISABLED]` e `[PATH_NOT_FOUND]`), causados pelo bloqueio de segurança à raiz pública do DBFS e pela sensibilidade a caracteres especiais e espaços vazios no nome dos arquivos (`Batata CONAB.csv`). Essas dificuldades foram superadas com a reestruturação e descoberta dos catálogos corretos via Unity Catalog (`workspace`).

Trabalhos Futuros:

Para enriquecimento profissional do portfólio, projeta-se a automação da ingestão de dados da CONAB diretamente via requisições de API para eliminar o processo de upload manual e o balanceamento sistemático das séries temporais para futuros modelos de Machine Learning preditivo.